Studienarbeit

Maximilian Gaul

In [1]:

```
import math
import pandas as pd
import numpy as np
from sklearn import preprocessing
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import confusion_matrix
from sklearn.neighbors import KNeighborsClassifier
from sklearn.svm import SVC
from sklearn.model_selection import cross_val_score
import matplotlib.pyplot as plt
%matplotlib inline
```

Aufgabe 1

Laden Sie die Daten aus `adult.data` in einen Pandas DataFrame

In [2]:

```
hdr = ["age", "workclass", "fnlwgt", "education", "education_num",
       "marital_status", "occupation", "relationship",
      "race", "sex", "capital_gain", "capital_loss",
      "hours_per_week", "native_country", "income"]
df = pd.read_csv("adult.data", skipinitialspace=True, names=hdr)
```

In [3]:

```
df
```

Out[3]:

	age	workclass	fnlwgt	education	education_num	marital_status	occupation	relations
0	39	State-gov	77516	Bachelors	13	Never-married	Adm-clerical	Not-in-fa
1	50	Self-emp-not-inc	83311	Bachelors	13	Married-civ-spouse	Exec-managerial	Husb
2	38	Private	215646	HS-grad	9	Divorced	Handlers-cleaners	Not-in-fa
3	53	Private	234721	11th	7	Married-civ-spouse	Handlers-cleaners	Husb
4	28	Private	338409	Bachelors	13	Married-civ-spouse	Prof-specialty	\
...	...	...	...	...	...	...	...	
32556	27	Private	257302	Assoc-acdm	12	Married-civ-spouse	Tech-support	\
32557	40	Private	154374	HS-grad	9	Married-civ-spouse	Machine-op-inspct	Husb
32558	58	Private	151910	HS-grad	9	Widowed	Adm-clerical	Unmar
32559	22	Private	201490	HS-grad	9	Never-married	Adm-clerical	Own-c
32560	52	Self-emp-inc	287927	HS-grad	9	Married-civ-spouse	Exec-managerial	\

32561 rows × 15 columns

Aufgabe 2

1) In den nominalen Daten sind noch unbekannte Werte, gekennzeichnet durch `?`, vorhanden. Bereinigen Sie die Daten, indem Sie alle Zeilen entfernen, die unbekannte Werte enthalten.

In [4]:

```
def query_builder(hdr, val):
    query = ''
    for h in hdr:
        query += '{0} != "{1}" &'.format(str(h), str(val))
    return query[:-1]

df = df.query(query_builder(hdr, "?"), inplace=False)
```

2) Entfernen Sie die Spalten `fnlwgt` und `income` als Features

In [5]:

```
X = df.copy()
X = X.drop(columns=["fnlwgt", "income"])
X
```

Out[5]:

	age	workclass	education	education_num	marital_status	occupation	relationship	ra
0	39	State-gov	Bachelors	13	Never-married	Adm-clerical	Not-in-family	Whi
1	50	Self-emp-not-inc	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	Whi
2	38	Private	HS-grad	9	Divorced	Handlers-cleaners	Not-in-family	Whi
3	53	Private	11th	7	Married-civ-spouse	Handlers-cleaners	Husband	Bla
4	28	Private	Bachelors	13	Married-civ-spouse	Prof-specialty	Wife	Bla
...	...	...	...	...	...	...	...	
32556	27	Private	Assoc-acdm	12	Married-civ-spouse	Tech-support	Wife	Whi
32557	40	Private	HS-grad	9	Married-civ-spouse	Machine-op-inspct	Husband	Whi
32558	58	Private	HS-grad	9	Widowed	Adm-clerical	Unmarried	Whi
32559	22	Private	HS-grad	9	Never-married	Adm-clerical	Own-child	Whi
32560	52	Self-emp-inc	HS-grad	9	Married-civ-spouse	Exec-managerial	Wife	Whi

30162 rows × 13 columns

3) Als Target soll das Feature `income` dienen, jedoch kommt nicht jeder Algorithmus mit nominalen Features klar. Konvertieren Sie das Target daher, sodass `income` den Wert `1` annimmt, falls das `income` ursprünglich den Wert `>50K` hat und `0` andernfalls

In [6]:

```
y = pd.DataFrame(
    {"income": np.where(df['income'] == ">50K", 1, 0)}
)
y
```

Out[6]:

	income
0	0
1	0
2	0
3	0
4	0
...	...
30157	0
30158	1
30159	0
30160	0
30161	1

30162 rows × 1 columns

4) Wieviel Prozent der Personen haben ein Einkommen von mehr als `50.000$` ?

In [7]:

```
total = len(y.index)
rich = len(y.query('income == 1').index)
print(rich / total, "% haben ein Einkommen von mehr als 50.000$")
```

```
0.24892248524633645 % haben ein Einkommen von mehr als 50.000$
```

5) Was ist die Genauigkeit eines naiven Modells, welches unabhängig von den tatsächlichen Features immer weniger als `50.000$` Einkommen zuweist? Dies ist das Mindestmaß an Genauigkeit, an dem sich ihre späteren Modelle messen müssen

In [8]:

```
tn = total - rich
print("total:", total)
print("tn:", tn)
```

```
total: 30162
tn: 22654
```

Die Genauigkeit ist definiert als $\frac{tp+tn}{tp+tn+fp+fn}$

`tp` ist die Anzahl der Personen, die das Modell als `>50k` einstuft und die auch tatsächlich `>50k` verdienen. Im Fall des naiven Modells ist `tp = 0` .

`tn` ist die Anzahl der Personen, die das Modell als `<=50k` einstuft und die auch tatsächlich `<=50k` verdienen. Im Fall des naiven Modells ist `tn = 22654` .

Der Wert des Nenners `tp + tn + fp + fn` entspricht der Gesamtzahl an Datensätzen. Damit lässt sich die Genauigkeit berechnen:

$$acc = \frac{0+22654}{30162} = 0.7511\%$$

Aufgabe 3

Schreiben Sie eine Methode `transform(X)` welche einen Feature-Dataframe `X` als Parameter erhält und einen transformierten DataFrame zurückgibt.

Die im Wertebereich verzerrten Features `capital_gain` und `capital_loss` sollten durch Logarithmierung normalisiert werden. Verwenden Sie dafür die Funktion

$$f : \mathbb{R} \to \mathbb{R}, f(x) = log(x + 1)$$

In [9]:

```
f = lambda x: math.log(x + 1)
```

In [10]:

```
def transform(X):
    _X = X.copy()
    _X["capital_gain"] = _X["capital_gain"].apply(f)
    _X["capital_loss"] = _X["capital_loss"].apply(f)

    numeric_headers = [
        "age", "education_num", "capital_gain",
        "capital_loss", "hours_per_week"
    ]

    nominal_headers = [
        "workclass", "education", "marital_status",
        "occupation", "relationship",
        "race", "sex", "native_country"
    ]

    for nmh in numeric_headers:
        min_max_scaler = preprocessing.MinMaxScaler()
        _X[nmh] = min_max_scaler.fit_transform(_X[nmh].values.reshape(-1, 1))
    _X = pd.get_dummies(_X, columns=nominal_headers)

    return _X
```

In [11]:

```
X_trans = transform(X)
X_trans
```

Out[11]:

	age	education_num	capital_gain	capital_loss	hours_per_week	workclass_Federal-gov
0	0.301370	0.800000	0.667492	0.0	0.397959	0
1	0.452055	0.800000	0.000000	0.0	0.122449	0
2	0.287671	0.533333	0.000000	0.0	0.397959	0
3	0.493151	0.400000	0.000000	0.0	0.397959	0
4	0.150685	0.800000	0.000000	0.0	0.397959	0
...	...	...	...	...	...	...
32556	0.136986	0.733333	0.000000	0.0	0.377551	0
32557	0.315068	0.533333	0.000000	0.0	0.397959	0
32558	0.561644	0.533333	0.000000	0.0	0.397959	0
32559	0.068493	0.533333	0.000000	0.0	0.193878	0
32560	0.479452	0.533333	0.835363	0.0	0.397959	0

30162 rows × 103 columns

Splitten Sie den Datensatz in einen Trainings- und Testdatensatz, wobei der Testdatensatz eine relative Größe von 20% haben soll. Verwenden Sie für die Reproduzierbarkeit einen `random_state = 0`

In [12]:

```
X_train, X_test, y_train, y_test = train_test_split(X_trans, y, test_size=0.2, random_state
```

Aufgabe 4

Wählen Sie drei verschiedene, in der Vorlesung behandelte Modelltypen und trainieren Sie die entsprechenden Modelle mit den Standardparametern (keine Parameter). Geben Sie zu jedem Modell die Genauigkeit auf dem Testdatensatz aus

Da es sich um ein (binäres) Klassifizierungsproblem handelt werden nur Modelltypen verwendet, die zur Klassifikation von Daten geeignet sind.

Gleichzeitig ist nicht bekannt, ob die Daten linear separierbar sind, d.h. einfache Neuronale Netze wie Perzeptron oder Adaline sind ungeeignet.

Daher werden folgende Modelle trainiert:

In [13]:

```
def model_to_accuracy(model, X_test, y_test):
    model_predict = model.predict(X_test)
    cf = confusion_matrix(
        y_true=y_test, y_pred=model_predict, labels=[1, 0]
    )

    TP = cf[0][0]
    FN = cf[0][1]
    FP = cf[1][0]
    TN = cf[1][1]

    return (TP + TN) / (TP + TN + FP + FN)
```

Logistic Regression

Logistische Regression ist hier ein potentiell geeignetes Modell, da es sich nur um ein binäres Klassifikationsproblem handelt.

Für das Modell wird `max_iter=1000` gesetzt, da es ansonsten zu einer Fehlermeldung kommt (Modell konvergiert nicht).

Die Logistische Regression kann auch mit Daten umgehen, die nicht linear trennbar sind.

In [14]:

```
lr = LogisticRegression(max_iter=1000).fit(X_train, y_train.values.ravel())
lr_accuracy = model_to_accuracy(lr, X_test, y_test)
print("Genauigkeit LogisticRegression:", lr_accuracy)
```

```
Genauigkeit LogisticRegression: 0.8395491463616774
```

K-Nearest-Neighbors

In [15]:

```
knn = KNeighborsClassifier().fit(X_train, y_train.values.ravel())
knn_accuracy = model_to_accuracy(knn, X_test, y_test)
print("Genauigkeit KNN:", knn_accuracy)
```

```
Genauigkeit KNN: 0.8168407094314603
```

Support Vector Klassifikation

In [16]:

```
svc = SVC().fit(X_train, y_train.values.ravel())
svc_accuracy = model_to_accuracy(svc, X_test, y_test)
print("Genauigkeit SVC:", svc_accuracy)
```

```
Genauigkeit SVC: 0.8392176363334991
```

Aufgabe 5

Wählen Sie das im vorherigen Schritt beste Modell und tunen Sie die Hyperparameter um möglichst eine noch bessere Performance zu bekommen

Das Modell mit der besten Genauigkeit ist das `LogisticRegression` -Modell.

Dieses Modell wird nun anhand der Hyperparameter `C` , `tol` , `solver` und `penalty` mit einer Rastersuche über alle Wertekombinationen getuned.

Bestimmte penalties kommen nur mit bestimmten solvern zurecht (und anders herum), darauf wird entsprechend Rücksicht genommen (siehe sklearn-Dokumentation).

In [17]:

```
C = [0.01, 0.05, 0.8, 2.0, 5.0, 10.0]
tol = [1e-5, 1e-4, 1e-3, 1e-2]
solver = ["newton-cg", "lbfgs", "liblinear", "sag", "saga"]
penalties = ["l1", "l2", "elasticnet"]

combinations = len(C) * len(tol) * len(solver) * len(penalties)
print("Trying", combinations, "combinations...")

i = np.arange(
    0, combinations, 1
)
combination_dict = []

vals = []
for c in C:
    for t in tol:
        for s in solver:
            for p in penalties:
                l1_ratio = None
                if p == "elasticnet":
                    s = "saga"
                    l1_ratio = 0.5
                elif s in ["newton-cg", "lbfgs", "sag"]:
                    p = "l2"
                model = LogisticRegression(
                    max_iter=1500, C=c, tol=t, penalty=p, solver=s, l1_ratio=l1_ratio
                )
                model.fit(X_train, y_train.values.ravel())
                acc = model_to_accuracy(model, X_test, y_test)
                vals.append(acc)
                combination_dict.append({
                    "C": c,
                    "tol": t,
                    "solver": s,
                    "penalty": p,
                    "l1_ratio": l1_ratio
                })
                if(len(vals) % 10 == 0):
                    print("We are at", len(vals))
```

```
Trying 360 combinations...
We are at 10
We are at 20
We are at 30
We are at 40
We are at 50
We are at 60
We are at 70
We are at 80
We are at 90
We are at 100
We are at 110
We are at 120
We are at 130
We are at 140
We are at 150
We are at 160
We are at 170
We are at 180
```

```
We are at 190
We are at 200
We are at 210
We are at 220
We are at 230
We are at 240
We are at 250
We are at 260
We are at 270
We are at 280
We are at 290
We are at 300
We are at 310
We are at 320
We are at 330
We are at 340
We are at 350
We are at 360
```

In [18]:

```
plt.plot(i, vals)
plt.xlabel("Durchlauf i")
plt.ylabel("Accuracy")
plt.show()
```

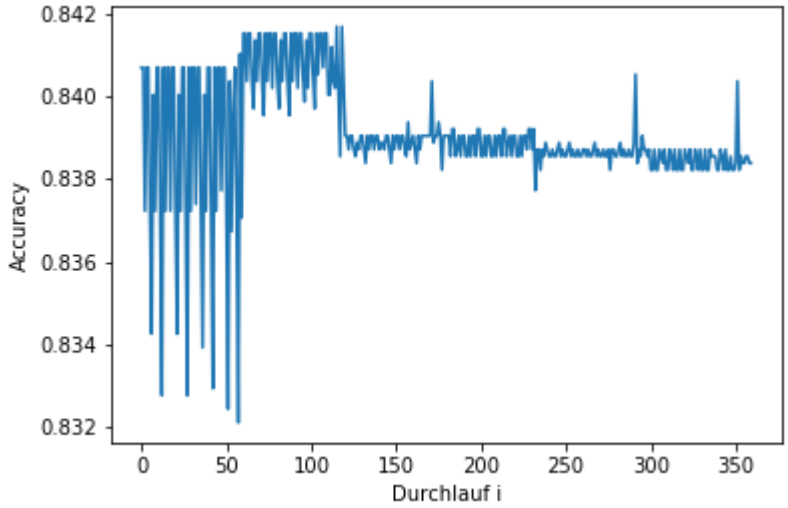

In [19]:

```
best_comb = combination_dict[np.argmax(vals)]
print("Maximale Genauigkeit", np.array(vals).max(), "für ", best_comb)
```

```
Maximale Genauigkeit 0.8417039615448367 für  {'C': 0.05, 'tol': 0.01, 'solve
r': 'sag', 'penalty': 'l2', 'l1_ratio': None}
```

Nach 360 Optimierungsversuchen konnte die Genauigkeit von `0.8395` auf `0.8417` des Logistischen Regressionsmodells gesteigert werden.

In [20]:

```
best_model = LogisticRegression(
    C=best_comb["C"],
    tol=best_comb["tol"],
    solver=best_comb["solver"],
    penalty=best_comb["penalty"]
)
best_model.fit(X_train, y_train.values.ravel())
```

Out[20]:

```
LogisticRegression(C=0.05, class_weight=None, dual=False, fit_intercept=Tru
e,
                   intercept_scaling=1, l1_ratio=None, max_iter=100,
                   multi_class='auto', n_jobs=None, penalty='l2',
                   random_state=None, solver='sag', tol=0.01, verbose=0,
                   warm_start=False)
```

Aufgabe 6

Erstellen Sie einen DataFrame mit Werten für eine erfundene Person

In [21]:

```
person = pd.DataFrame({
    "age": 23,
    "workclass": "Self-emp-inc",
    "education": "Bachelors",
    "education_num": 12,
    "marital_status": "Never-married",
    "occupation": "Tech-support",
    "relationship": "Unmarried",
    "race": "White",
    "sex": "Male",
    "capital_gain": 5,
    "capital_loss": 0,
    "hours_per_week": 20,
    "native_country": "Germany"
}, index=[0])
person
```

Out[21]:

	age	workclass	education	education_num	marital_status	occupation	relationship	race	
0	23	Self-emp-inc	Bachelors	12	Never-married	Tech-support	Unmarried	White	M

Transformieren Sie diese Person ebenfalls mit Hilfe der `transform` -Methode. Da die Normierung nur auf größeren Datensätzen Sinn macht, vereinen Sie den ursprünglichen DataFrame und die neue Person und transformieren das Gesamtpaket

In [22]:

```
Xp = pd.concat((X, person))
Xp_trans = transform(Xp)
```

In [23]:

```
tail = Xp_trans.tail(1)
tail
```

Out[23]:

	age	education_num	capital_gain	capital_loss	hours_per_week	workclass_Federal-gov	wc
0	0.082192	0.733333	0.15563	0.0	0.193878	0	

1 rows × 103 columns

Machen Sie mit Hilfe des Modells eine Vorhersage. Würde die Person als potentieller Spender ausgewählt werden?

In [24]:

```
p = best_model.predict(Xp_trans)[-1]
```

In [25]:

```
p
```

Out[25]:

```
0
```

Die Person würde nicht als potentieller Spender ausgewählt werden da die Vorhersage die Klasse `0` zurückliefert (`<=50k`).